


Segmentação da Articulação Sacroilíaca em Imagens de Ressonância Magnética Utilizando a Rede Neural Convolucional U-Net no Framework nnU-Net



Lucas de Almeida Louzada¹, Paulo Mazzoncini de Azevedo Marques²

¹Graduação em Informática Biomédica, Faculdade de Medicina de Ribeirão Preto, Universidade de São Paulo, Ribeirão Preto, SP, Brasil.

²Orientador, Departamento de Imagens Médicas, Hematologia e Oncologia Clínica.

Introdução

A avaliação por imagem é um processo fundamental no diagnóstico de pacientes com espondiloartropatias soronegativas, grupo de doenças inflamatórias sistêmicas crônicas que, caracteristicamente, apresentam manifestações clínicas precoces nas articulações sacroilíacas (AS) e podem causar um grande impacto na vida de portadores.

Este projeto propôs a aplicação da arquitetura de rede neural convolucional U-Net, através do framework nnU-Net, para identificar e segmentar a articulação sacroilíaca em imagens de ressonância magnética (RM). A correta identificação e segmentação dessa articulação são passos cruciais para que modelos de aprendizado de máquina possam ser empregados de maneira eficaz no auxílio ao diagnóstico da sacroileíte e de outras condições associadas à inflamação desta articulação.

Materiais e Métodos

O material principal deste trabalho foi o conjunto de imagens de RM da AS, junto com suas respectivas máscaras de segmentação manual. Todas as imagens foram segmentadas manualmente por especialistas em um fundo escuro para separar a região de interesse (ROI). Este conjunto foi anteriormente estruturado e anonimizado para uso público, com aprovação do Comitê de Ética em Pesquisa do Hospital das Clínicas de Ribeirão Preto (CEP-HCRP), sob parecer número 1.951.052.

As imagens foram organizadas e pré-processadas para serem usadas no treinamento da rede. Foram separadas em conjunto de teste e de treino e passaram por um processo de *data augmentation*. A Figura 1 contém exemplos das imagens após o pré-processamento. Foram treinados 5 modelos utilizando o framework nnU-Net, com um conjunto de treino de 910 imagens, seguindo a técnica de validação cruzada 5-fold. Em cada modelo, um dos 5 subconjuntos foi utilizado para validação, enquanto os outros 4 subconjuntos foram usados para treino.

O *framework* nnU-Net fornece um conjunto de ferramentas para implementação de um *pipeline* completo para a tarefa de segmentação em imagens biomédicas. Identificando características do conjunto de imagens de entrada e selecionando os parâmetros adequados para a criação automática de uma arquitetura de rede utilizando-se de variações da rede U-Net, ao mesmo tempo que expõe as principais configuração em forma de variáveis, permitindo um ajuste fino do treinamento. A arquitetura básica da rede U-Net é exemplificada na Figura 2, consistindo de um caminho contrativo (*downsampling*) e um caminho expansivo (*upsampling*).

Os modelos foram treinados utilizando o ambiente do Google Colab, totalizando um tempo de 35 horas para concluir o processo. A Figura 3 ilustra a progressão do treinamento, onde é possível observar uma convergência para valores estáveis após aproximadamente 20 *epochs*. Este comportamento indica um bom ajuste do modelo aos dados, sem evidências de *overfitting* significativo. Após a conclusão, o nnU-Net realizou um pós-processamento para otimizar as configurações dos modelos treinados.




Figura 1. Imagens após pré-processamento e *data augmentation*.

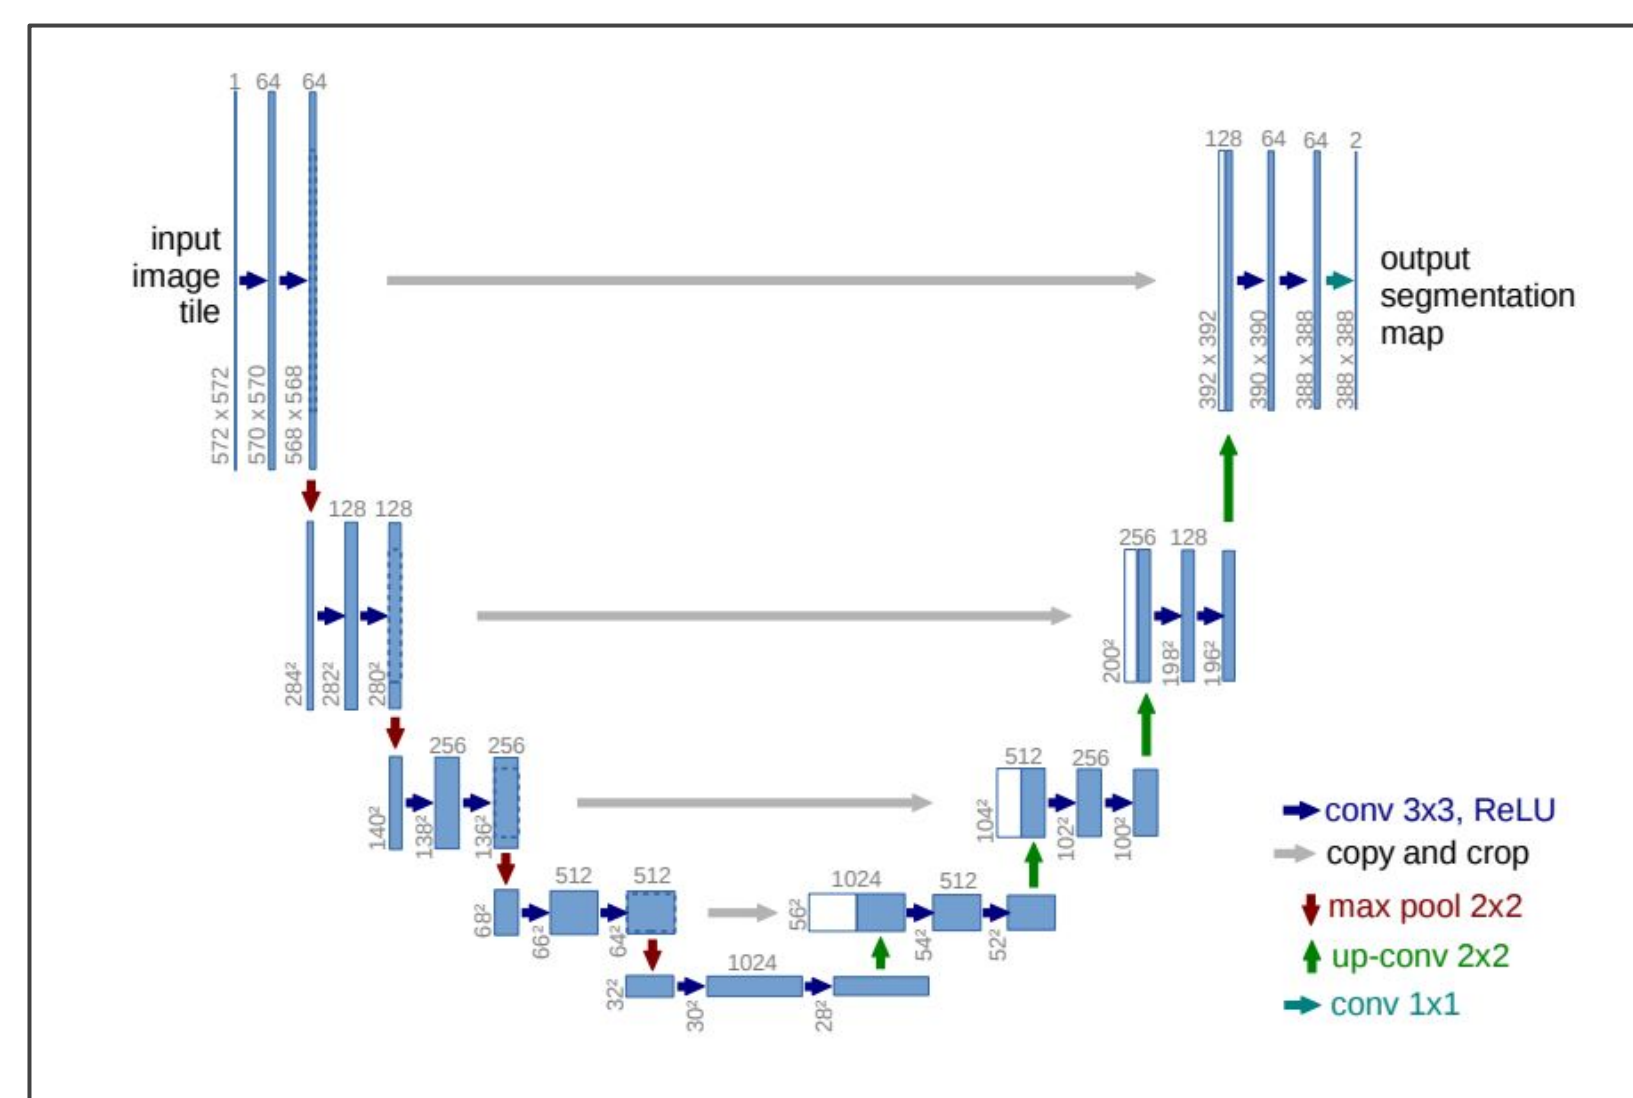


Figura 2 Arquitetura da U-Net (exemplo para imagens de resolução mais baixa de 32x32 pixels). Cada caixa azul corresponde a um mapa de características multi-canal, com o número de canais indicado acima da caixa. O tamanho em x-y é fornecido no canto inferior esquerdo. Caixas brancas representam mapas de características que são copiados, e as setas denotam as diferentes operações.

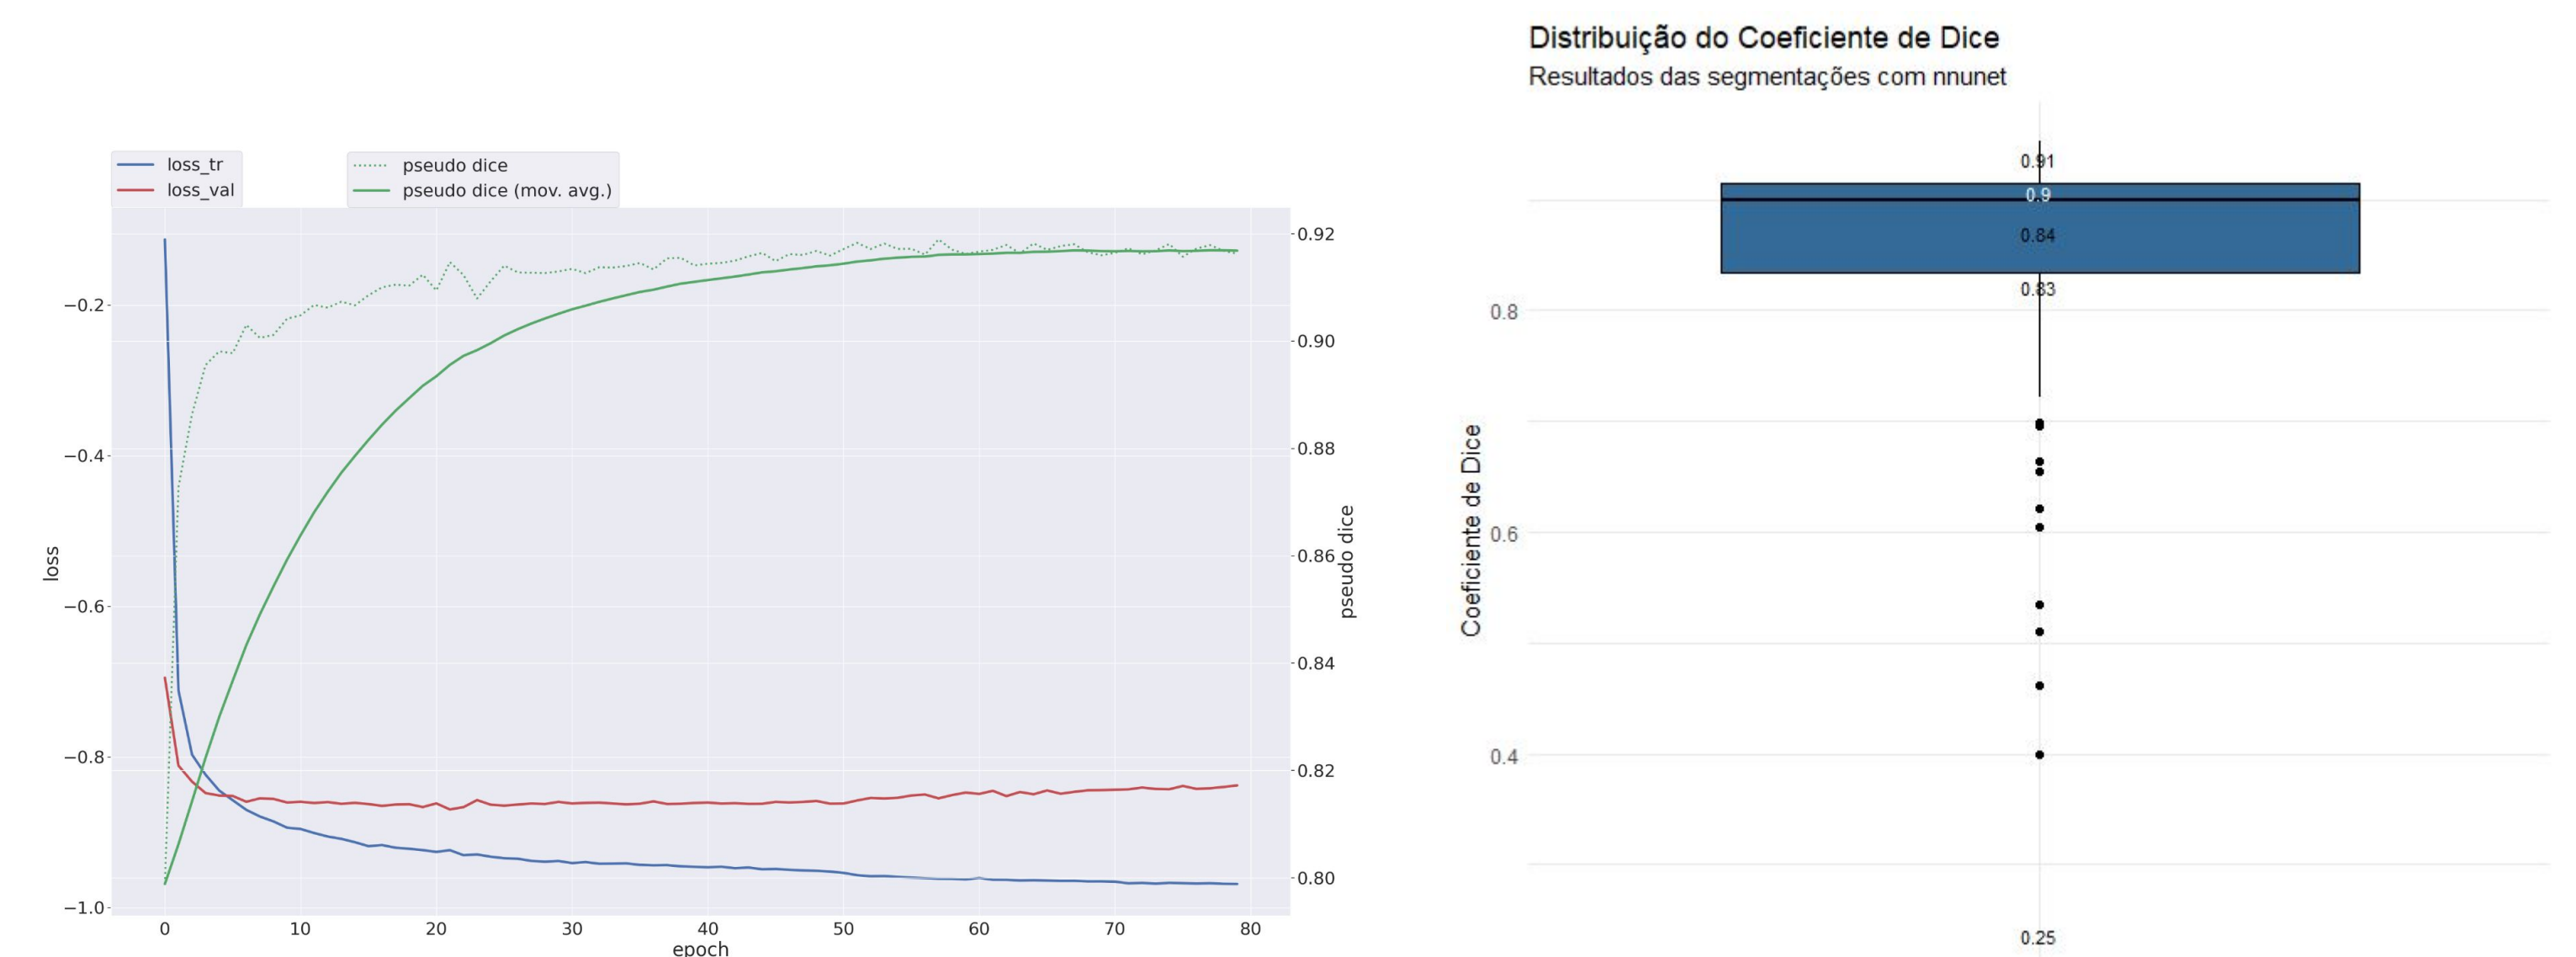


Figura 3. Evolução das perdas de treinamento e validação ao longo dos epochs

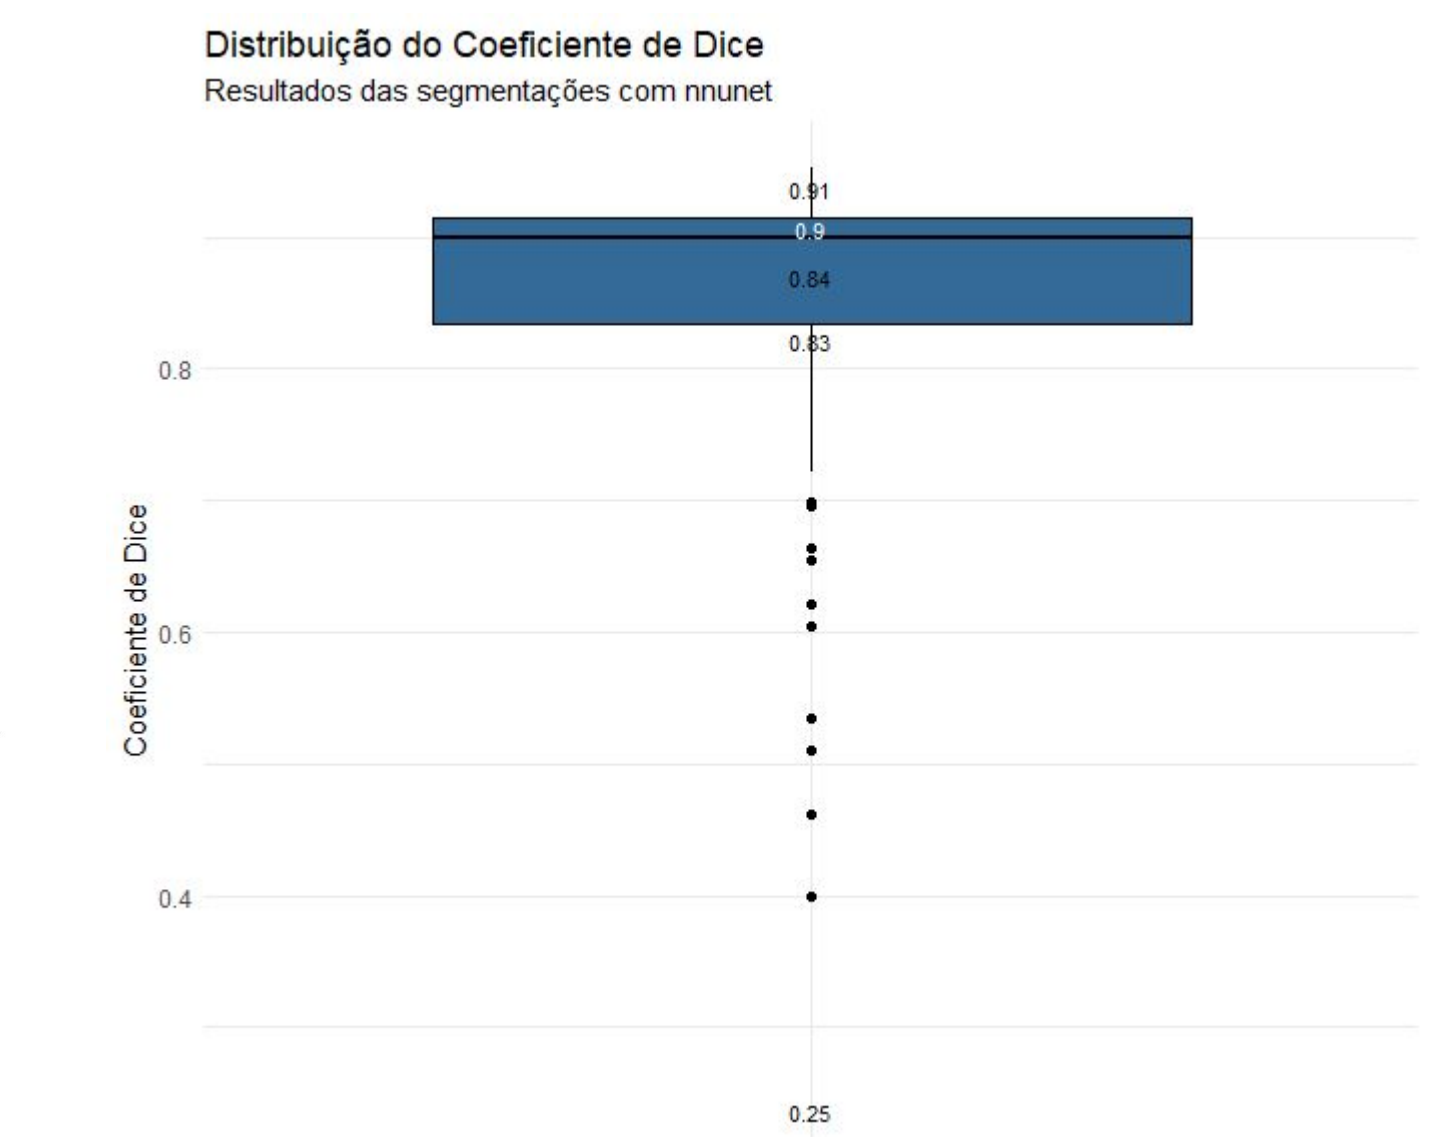


Figura 4. Box-plot da distribuição dos coeficientes Dice obtidos

Resultados

Ao final do treinamento, foram geradas as previsões a partir do conjunto de testes. Pode-se observar a distribuição dos Coeficientes Dice obtidos na Figura 4.

As Figuras 5 e 6 são exemplos das segmentações realizadas, com a imagem original, seguida da máscara original, a máscara predita e a máscara predita pós-processada (PP). A Figura 7 exemplifica a aplicação prática do projeto, sobrepondo um *bounding box* nas imagens de RM, localizando assim as ROIs.




Figura 5. Exemplo de predição




Figura 6. Exemplo de predição




Figura 7. Exemplos de imagens com sobreposição da região de interesse.

Conclusão

Os resultados demonstram que a U-Net, implementada por meio do framework nnU-Net, possui um grande potencial para uso em contextos clínicos. Porém ainda há muito espaço para melhora, incluindo a possibilidade de trabalhar com uma gama mais ampla de transformações nas imagens, gerando ainda mais robustez ao modelo. Ademais, seria de grande valor explorar mais as configurações da rede, buscando os parâmetros que tragam resultados otimizados.

Referências

- CASTRO, M. R. d. et al. Espondiloartropatias: critérios de ressonância magnética na detecção da sacroileíte. Radiologia Brasileira, SciELO Brasil, v. 50, p. 258–262, 2017.
- ISENSE, F. et al. nnu-net: Self-adapting framework for u-net-based medical image segmentation. arXiv preprint arXiv:1809.10486, 2018.
- RONNEBERGER, O.; FISCHER, P.; BROX, T. U-net: Convolutional networks for biomedical image segmentation. In: SPRINGER. Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5–9, 2015, Proceedings, Part III 18. [S.l.], 2015. p. 234–241.
- SIDDIQUE, N. et al. U-net and its variants for medical image segmentation: A review of theory and applications. Ieee Access, IEEE, v. 9, p. 82031–82057, 2021.
- ZHANG, K. et al. Automatic image segmentation and grading diagnosis of sacroiliitis associated with as using a deep convolutional neural network on ct images. Journal of Digital Imaging, Springer, p. 1–10, 2023.