




FMRP - USP/RP

Segmentação da Articulação Sacroilíaca em Imagens de Ressonância Magnética Utilizando a Rede Neural Convolucional U-Net no Framework nnU-Net

Trabalho de Conclusão de Curso - Informática Biomédica

Lucas de Almeida Louzada

Orientador: Prof. Dr Paulo Mazzoncini de Azevedo
Marques





Tópicos

- Introdução
- Objetivos
- Materiais e Métodos
- Resultados
- Conclusão

Introdução

CONTEXTUALIZAÇÃO

- **Espondiloartropatias Soronegativas (EAS):** Grupo de doenças inflamatórias sistêmicas crônicas que, caracteristicamente, apresentam **manifestações clínicas precoces** nas articulações sacroilíacas (AS).
- Podem causar um grande impacto na qualidade de vida dos portadores.
- Em casos mais graves pode acometer a coluna vertebral, podendo evoluir com rigidez e limitação funcional progressiva, como no caso da **espondilite anquilosante**.


Introdução

- Englobam condições como: espondilite anquilosante, artrite psoriásica, artrite reativa, entre outras.
- Compartilham aspectos clínicos, radiológicos e laboratoriais comuns, tais como:
 - Dor axial inflamatória associada à artrite;
 - **Sacroiliíte**;
 - Ausência de anticorpos reumatóides no sangue, caracterizando-as como "soronegativas".
- As **manifestações clínicas precoces** nas AS são de lenta evolução e sem marcadores laboratoriais específicos que demonstrem sua atividade, sendo caracterizadas pelo processo inflamatório não-infeccioso das mesmas, nomeado Sacroiliíte.
- Sacroiliíte é critério diagnóstica das EAS.

Introdução


- Diagnóstico e a avaliação de sacroiliíte baseados principalmente em exames de imagem, como a ressonância magnética (RM).
- Devido à complexidade da região, processo diagnóstico não é uma tarefa trivial.

Imagens de RM da AS - à esquerda: negativo para sacroiliíte; à direita: positivo para sacroiliíte.



U-Net

- Arquitetura especialmente projetada para segmentação de imagens biomédicas



Arquitetura da U-Net

Introdução

nnU-Net

- “*no-new-U-Net*”.
- *Framework* que trás ferramentas para implementação de fluxo completo e automatizado de segmentação de imagens biomédicas.
- A partir da entrada, gera uma arquitetura baseada na U-Net original.
- Expõe principais configurações em forma de variáveis, permitindo um ajuste fino dos parâmetros.

Isensee et al. arXiv, 2018.

Zhang et al. Journal of Digital Imaging, 2023.

Coeficientes Dice e IoU

- Métricas para avaliar a similaridade da predição em relação ao conjunto original.
- Valores mais próximos de 1 indicam uma maior precisão na segmentação, enquanto valores mais baixos indicam uma precisão menor.

$$DICE(A, B) = \frac{2 \times |A \cap B|}{|A| + |B|}$$

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Objetivos


Implementar, treinar e analisar os resultados da aplicação da rede **U-Net**, utilizando o framework **nnU-Net**, para a identificação e segmentação automática das AS em imagens de RM.

ETAPAS:

- Pré-processamento do conjunto de imagens;
- *Data Augmentation*;
- Organização do conjunto de imagens;
- Implementação do *framework* e treinamento;
- Testes e ajustes dos modelos;
- Pós-processamento;
- Análise dos resultados;


Materiais e Métodos

- Principal Material: Conjunto de imagens de RM.
- De 51 pacientes obtidas com sequência Spectral Attenuated Inversion Recovery (SPAIR) e de 46 pacientes obtidas com sequência Short Tau Inversion Recovery (STIR).
- Anteriormente estruturado e anonimizado para uso público, com aprovação do Comitê de Ética em Pesquisa do Hospital das Clínicas de Ribeirão Preto (CEP-HCRP), sob parecer número 1.951.052.



pré-processamento


- Verificação da presença de atributos essenciais para pré-processamento.
- Conversão de DICOM para PNG.
- Técnica de windowing: realce de faixas de intensidades de pixel.
- Verificação de paridade das imagens e máscaras de segmentação e recorte para padronização de tamanhos.
- Pré-processamento das máscaras: binarização dos pixels e remoção de ruídos.
- Conjunto de treino (80%) e conjunto de testes (20%).



Exemplo das imagens após o pré-processamento

Data Augmentation

- Conceito fundamental para atingir melhores resultados no treinamento de modelos U-Net.
- Biblioteca Python Albumentations, aumento de 2x do conjunto de treino, resultando em 910 imagens para treinamento.
- Transformações aplicadas: HorizontalFlip, VerticalFlip, Rotate, RandomSizedCrop, GridDistortion.



Exemplo das imagens após processo de data augmentation

Implementação da Arquitetura

CONFIGURAÇÃO E TESTES

- Google Colab.
- Organização das imagens seguindo estrutura específica do nnU-Net.
- Maioria das configurações foi mantida no valor padrão.
- Alterados iterações por *epoch* e total de *epochs* (250 e 80, respectivamente)

```
nnUNet_raw/Dataset001_SacroRM/  
├── dataset.json  
├── imagesTr  
│   ├── SacroRM_001_0000.png  
│   ├── SacroRM_001_0001.png  
│   ├── SacroRM_001_0002.png  
│   ├── SacroRM_001_0003.png  
│   ├── SacroRM_002_0000.png  
│   ├── SacroRM_002_0001.png  
│   ├── SacroRM_002_0002.png  
│   ├── SacroRM_002_0003.png  
│   └── ...  
├── imagesTs  
│   ├── SacroRM_485_0000.png  
│   ├── SacroRM_485_0001.png  
│   ├── SacroRM_485_0002.png  
│   ├── SacroRM_485_0003.png  
│   ├── SacroRM_486_0000.png  
│   ├── SacroRM_486_0001.png  
│   ├── SacroRM_486_0002.png  
│   ├── SacroRM_486_0003.png  
│   └── ...  
└── labelsTr  
    ├── SacroRM_001.png  
    ├── SacroRM_002.png  
    └── ...
```

Estrutura de diretórios para uso do
nnU-Net

TREINAMENTO

- Técnica de validação cruzada 5-Fold.
- Conjunto de treino, com 910 imagens, foi dividido em 5 subconjuntos, e em cada modelo, um desses subconjuntos foi utilizado para validar o treinamento e os outros quatro subconjuntos foram utilizados para treino.
- Tempo médio dos *epochs*: *5min*.
- Aproximadamente 35 horas de treinamento.

Materiais e Métodos




MÉTRICAS TREINAMENTO

Métricas de cada modelo

Modelo	Coefficiente Dice
Fold_0	0.9177
Fold_1	0.9144
Fold_2	0.9126
Fold_3	0.9078
Fold_4	0.9136

Após 5-Fold Cross Validation


Coefficiente Dice	IoU
0.9132	0.8417



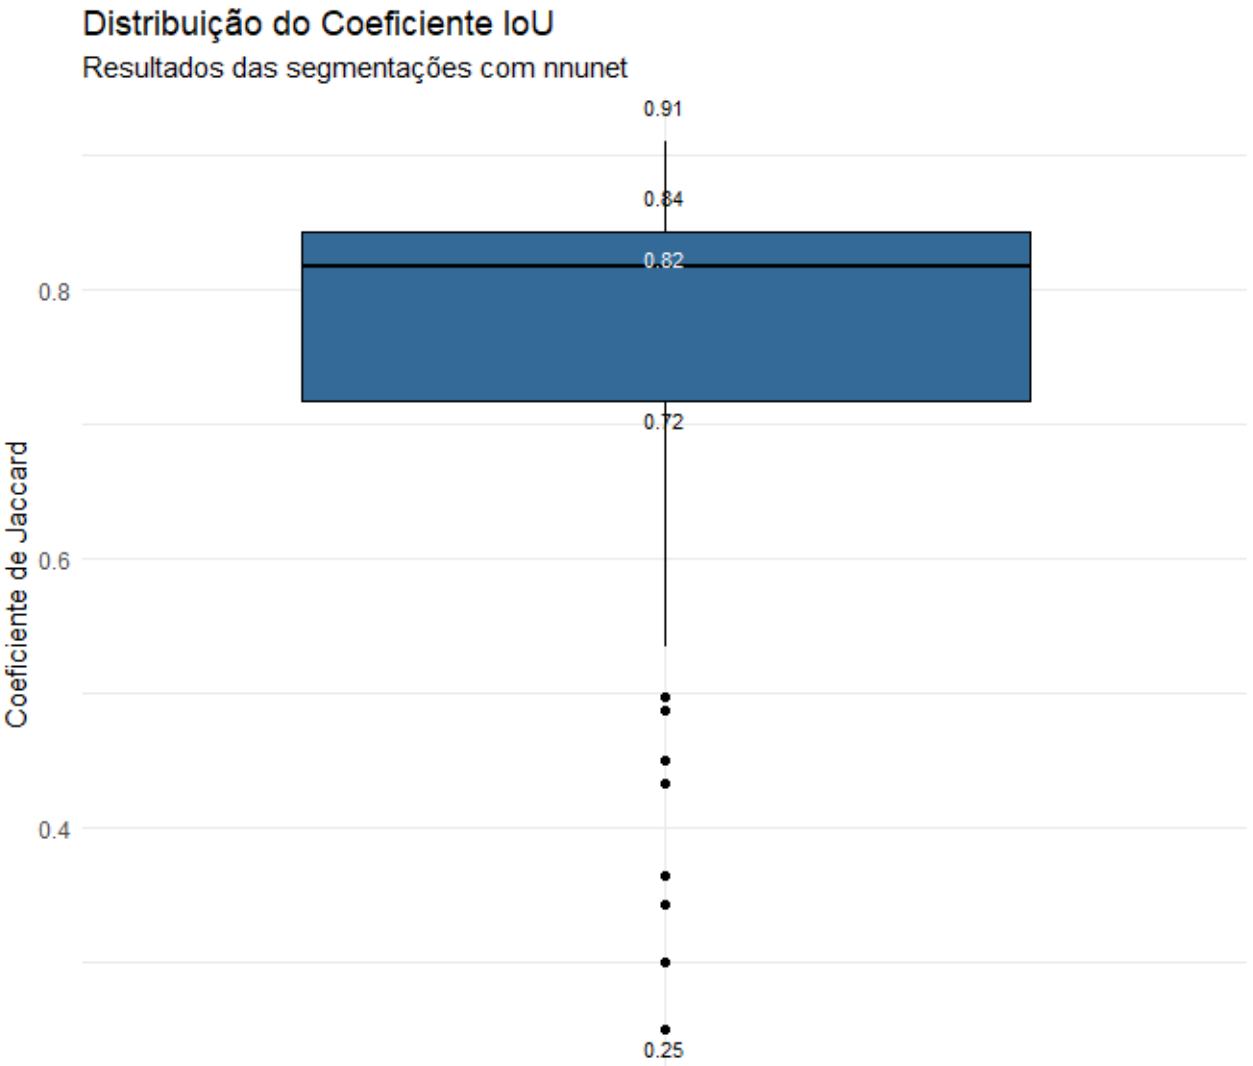
Tempo dos *epochs*, Progressão do Learning Rate e Progressão das perdas e pseudo-dice

PÓS-PROCESSAMENTO

- Após a realização das inferências utilizando o nnU-Net, foi aplicado o pós-processamento.
- nnU-Net remove todos os componentes menores, deixando apenas o maior. Esse passo é feito na suposição de que os componentes menores são provavelmente erros de segmentação (ruídos), e que a estrutura real que está sendo segmentada é o componente maior.





	Min.	1° Quadrante	Mediana	Média	3° Quadrante	Max.
Dice	0.3996	0.8348	0.8992	0.8542	0.9147	0.9528

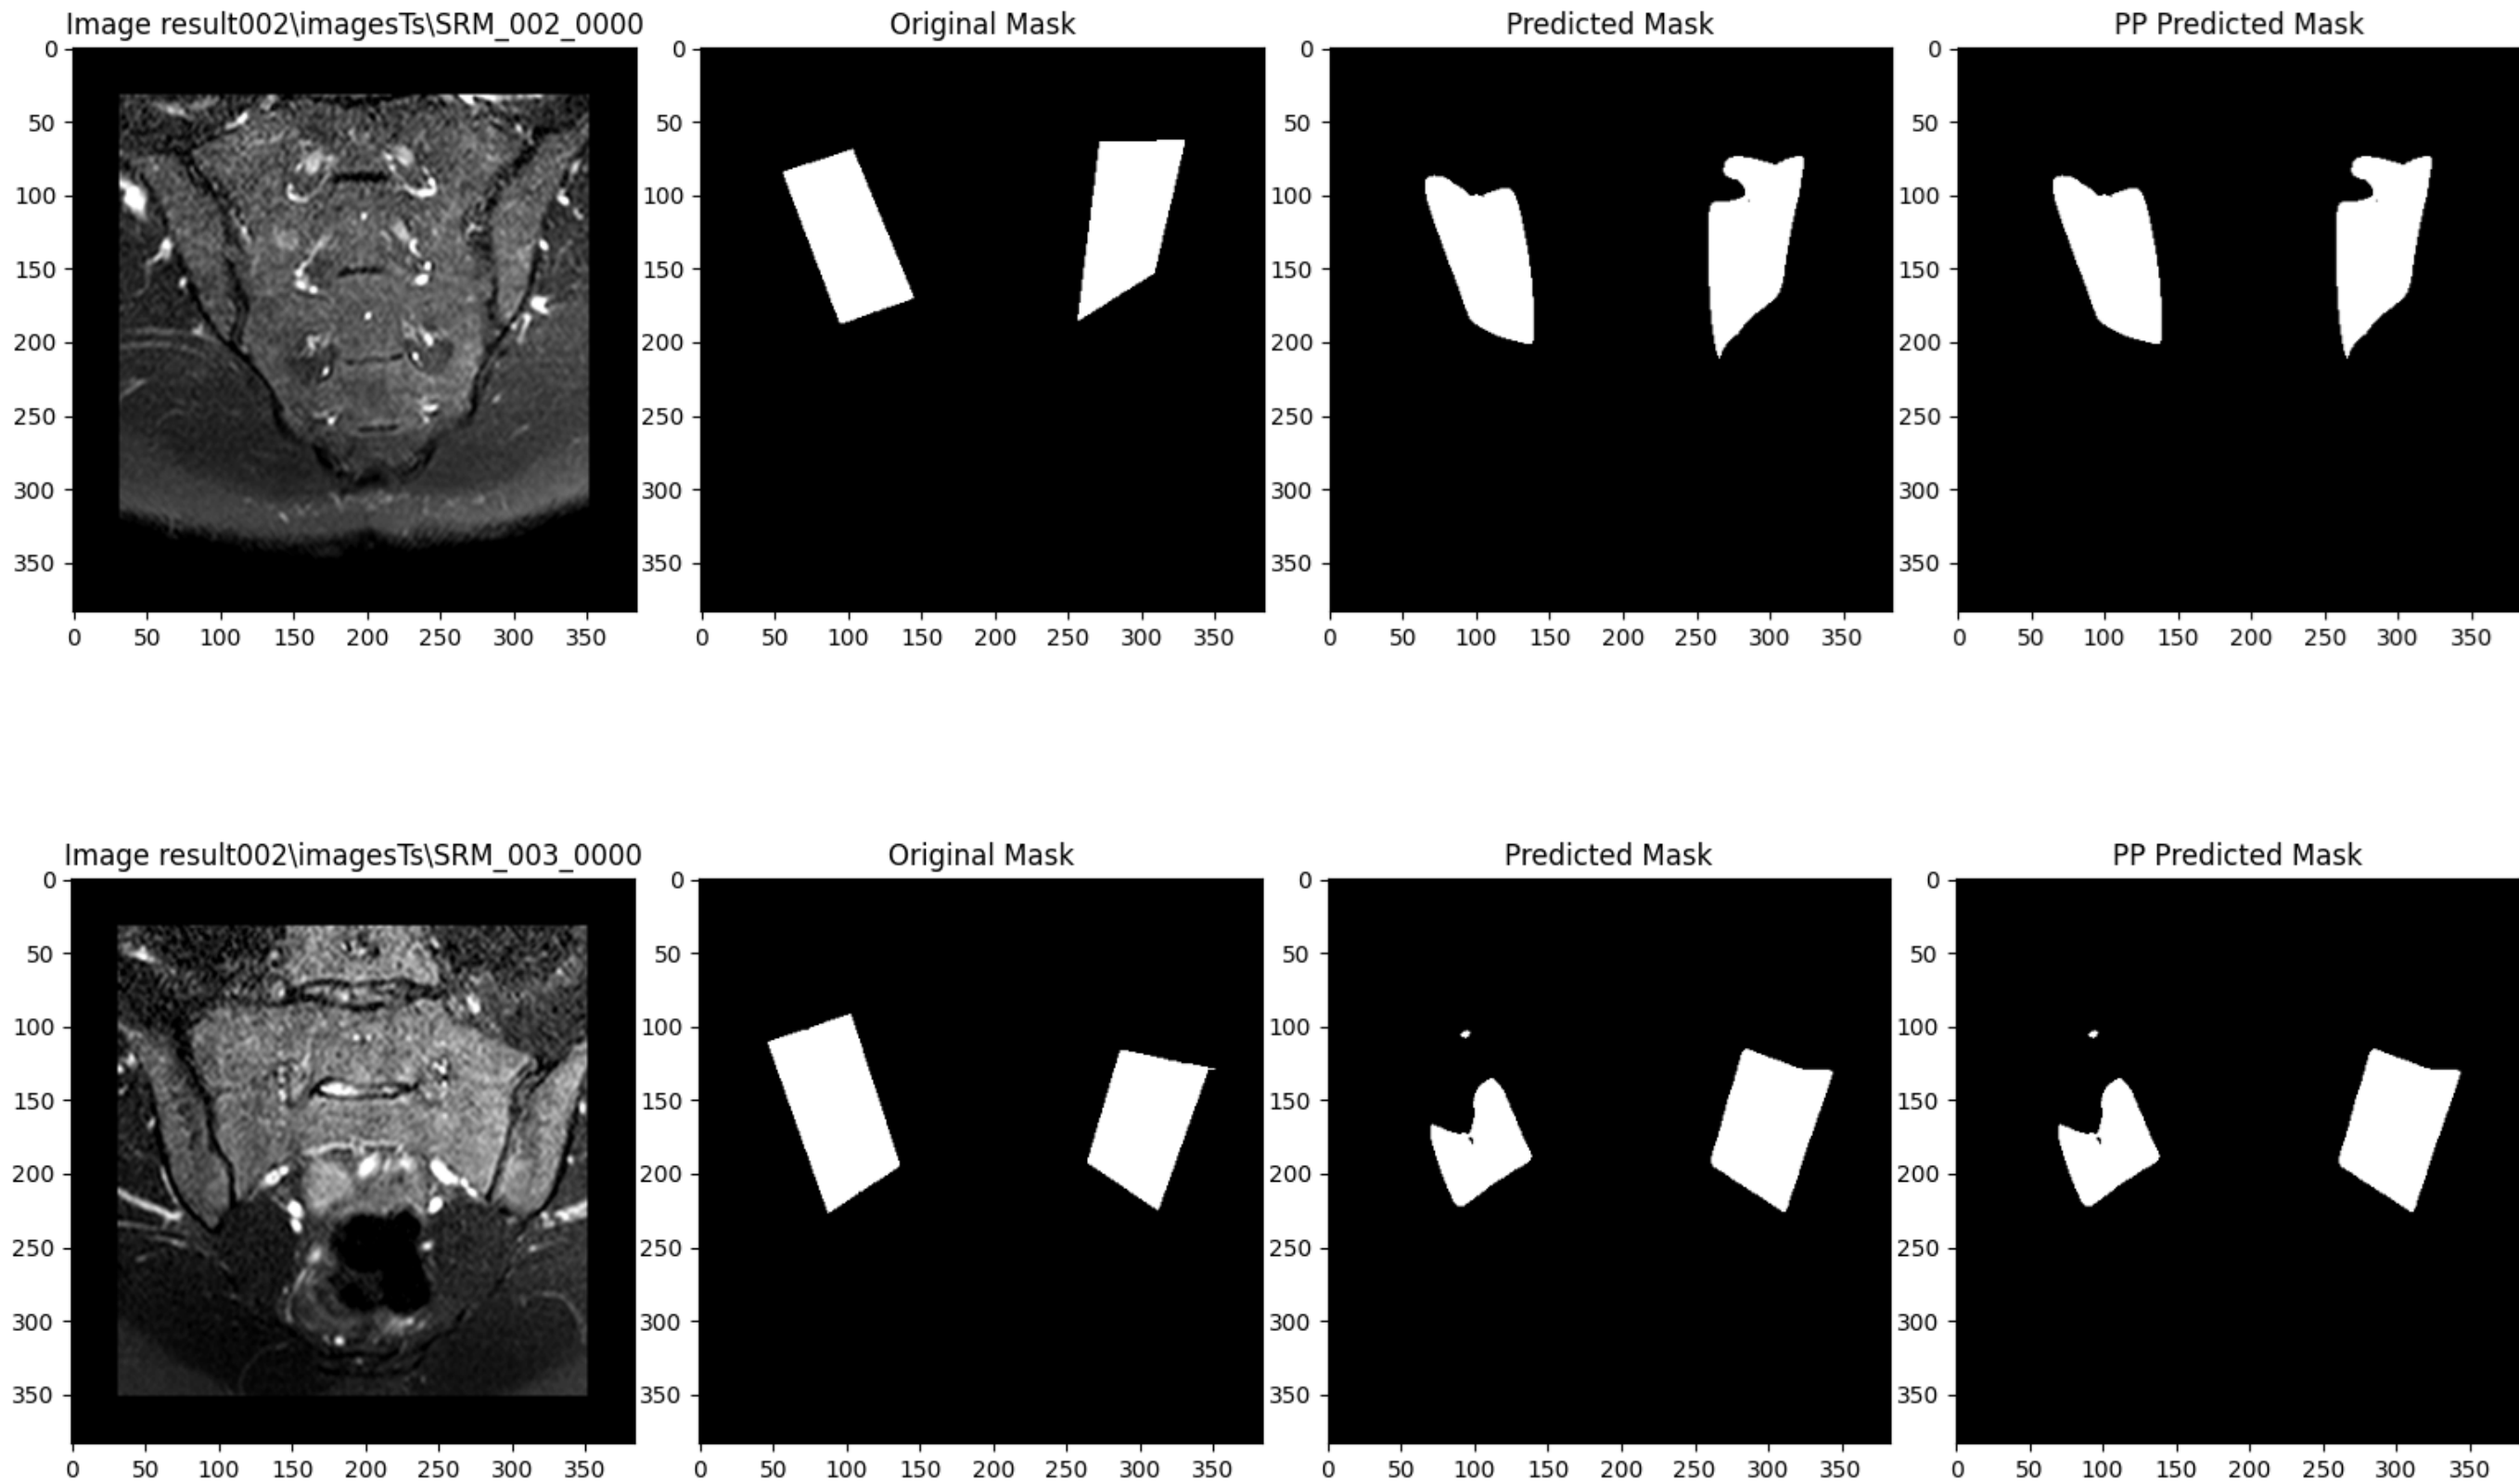


	Min.	1° Quadrante	Mediana	Média	3° Quadrante	Max.
IoU	0.2497	0.7164	0.8168	0.7576	0.8429	0.9099


PREDIÇÕES



PREDIÇÕES







PREDIÇÕES




Resultados


APLICAÇÃO PRÁTICA



Conclusão




Apresenta grande potencial para a aplicabilidade no contexto clínico



Há muito espaço para melhora, incluindo:

- Explorar parâmetros e configurações;
- Trabalhar com maior variedade de transformações nas imagens;
- Utilizar segmentações mais específicas;



Continuidade do projeto:

- *Pipeline* completo para segmentação e classificação da sacroilíte ativa.

Obrigado!